

Trabajo Final: Data Wrangling "CityTyci"

Contexto

Como parte del equipo de Ingeniería de Software de la ciudad, se les ha encomendado la tarea de centralizar la información proveniente de miles de sensores urbanos. Debido a que la infraestructura de la ciudad se ha actualizado en etapas a lo largo de los últimos 10 años, conviven múltiples generaciones de hardware y versiones de firmware.

El objetivo es construir una especie de **Refinería de Datos** capaz de procesar un flujo masivo de eventos heterogéneos y transformarlos en un dataset limpio, tipado y validado.

Detalles

El sistema recibirá un archivo JSON con una lista de eventos crudos. Sin embargo, los datos presentan los siguientes desafíos:

- **Evolución de Esquemas:** Existen al menos 3 versiones detectadas de sensores (v1.0, v1.5 y v2.0). Cada una representa la información de manera distinta: algunos usan campos planos, otros usan mapas de "payload" o "attributes" genéricos.
- **Inconsistencia de Nomenclatura:** Los nombres de los campos varían según la versión (ej. SPD, velocity, speedKmh). El uso de mayúsculas y minúsculas no es constante.
- **Ruido y Errores de Sensor:** Algunos sensores reportan valores fuera de rango (outliers) o nulos que deben ser descartados o saneados.
- **Unidades Heterogéneas:** Se sabe que las versiones más antiguas reportaban ciertas medidas en unidades imperiales (Fahrenheit) mientras que las modernas usan el sistema métrico.

Requerimientos de Implementación

Para garantizar una arquitectura robusta, el software deberá implementarse siguiendo estos principios:

A. Arquitectura Híbrida

- **Infraestructura:** El motor de procesamiento, la lectura de archivos y la coordinación del pipeline deben diseñarse priorizando la extensibilidad.
- **Modelo de Dominio:** Definición de la taxonomía de eventos.

B. Lógica de Procesamiento

- Debe evitarse el uso excesivo de if-else o instanceof tradicionales.
- El procesamiento debe ser **exhaustivo**; el compilador debe ser capaz de validar que todos los tipos de eventos conocidos son procesados.

Objetivos de Salida (Métricas)

El programa debe procesar el archivo y emitir un reporte en consola con:

1. Total de registros procesados con éxito (excluyendo basura).
2. Promedio de velocidad de tráfico (sólo de registros válidos).
3. Conteo de "Eventos Críticos" (definidos por lógica de negocio: temperaturas extremas, baches en avenidas principales, etc.).
4. Distribución de versiones de esquema detectadas.

Evaluación

Se evaluará la elegancia de la solución, el manejo de errores y la capacidad del sistema para ser testeado mediante pruebas unitarias sin el uso de mocks complejos.